

R untuk Eksplorasi Data Biodiversitas

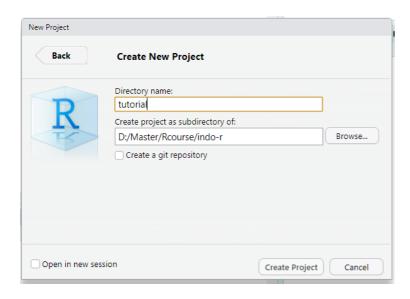
Sabhrina Gita Aninta

Tambora Muda Indonesia / Komunitas R Indonesia 2019/05/16 (updated: 2019-05-17)

Teknis tutorial

Silakan memulai dari membuka project baru dari Rstudio:

File - New Project... - New Directory - New Project

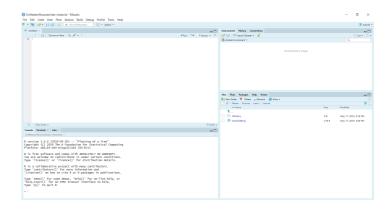


Pilih lokasi proyek dan tulis nama folder yang jadi lokasi proyek sesuka Anda, lalu klik Create Project.

Teknis tutorial

Sesi baru untuk tempat Anda melakukan proyek akan terbuka, lalu Anda dapat membuka skrip R baru untuk menulis kode R Anda





Jangan lupa menyimpan skrip Anda sebelum memulai menuliskan kode.

Ikuti tutorial dengan mengetikkan kode yang dipresentasikan dalam skrip Anda.



Memperoleh Data Biodiversitas

Kata "biodiversitas" dalam bahasa Indonesia baku umum dikenal dalam frase "keanekaragaman hayati" atau disingkat "kehati".

Kata "biodiversitas" dalam bahasa Indonesia baku umum dikenal dalam frase "keanekaragaman hayati" atau disingkat "kehati".

Meski tidak baku, kata "biodiversitas" lebih populer di kalangan praktisi dibandingkan "kehati" yang lebih umum digunakan di lingkungan pemerintah.

Kata "biodiversitas" dalam bahasa Indonesia baku umum dikenal dalam frase "keanekaragaman hayati" atau disingkat "kehati".

Meski tidak baku, kata "biodiversitas" lebih populer di kalangan praktisi dibandingkan "kehati" yang lebih umum digunakan di lingkungan pemerintah.

Data biodiversitas ada berbagai macam:

Kata "biodiversitas" dalam bahasa Indonesia baku umum dikenal dalam frase "keanekaragaman hayati" atau disingkat "kehati".

Meski tidak baku, kata "biodiversitas" lebih populer di kalangan praktisi dibandingkan "kehati" yang lebih umum digunakan di lingkungan pemerintah.

Data biodiversitas ada berbagai macam:

• perjumpaan (*occurrence*)

Kata "biodiversitas" dalam bahasa Indonesia baku umum dikenal dalam frase "keanekaragaman hayati" atau disingkat "kehati".

Meski tidak baku, kata "biodiversitas" lebih populer di kalangan praktisi dibandingkan "kehati" yang lebih umum digunakan di lingkungan pemerintah.

Data biodiversitas ada berbagai macam:

- perjumpaan (*occurrence*)
- sekuen DNA/RNA/protein

Kata "biodiversitas" dalam bahasa Indonesia baku umum dikenal dalam frase "keanekaragaman hayati" atau disingkat "kehati".

Meski tidak baku, kata "biodiversitas" lebih populer di kalangan praktisi dibandingkan "kehati" yang lebih umum digunakan di lingkungan pemerintah.

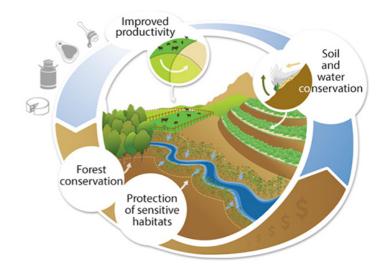
Data biodiversitas ada berbagai macam:

- perjumpaan (*occurrence*)
- sekuen DNA/RNA/protein
- karakter morfologi dan fisiologi

Mengapa data biodiversitas?

Seluruh hidup kita bergantung kepada biodiversitas:

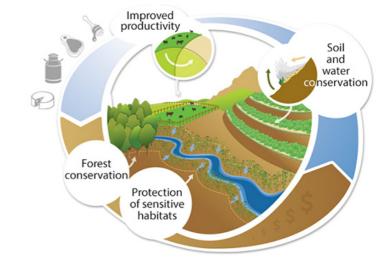
- air bersih
- udara bersih
- makanan
- tempat tinggal
- kesehatan



Mengapa data biodiversitas?

Seluruh hidup kita bergantung kepada biodiversitas:

- air bersih
- udara bersih
- makanan
- tempat tinggal
- kesehatan



Manajemen biodiversitas yang baik memerlukan manajemen data biodiversitas yang baik.

Era informasi memungkinkan (dan menuntut) kita memanajemen informasi dengan sistematis dan integratif agar data dapat diakses dan digunakan kembali oleh banyak orang.

Era informasi memungkinkan (dan menuntut) kita memanajemen informasi dengan sistematis dan integratif agar data dapat diakses dan digunakan kembali oleh banyak orang.

Berbagai pangkalan data kehati tersebar di dalam jaringan:

Era informasi memungkinkan (dan menuntut) kita memanajemen informasi dengan sistematis dan integratif agar data dapat diakses dan digunakan kembali oleh banyak orang.

Berbagai pangkalan data kehati tersebar di dalam jaringan:

• Global Biodiversity Information Facility (GBIF)

Era informasi memungkinkan (dan menuntut) kita memanajemen informasi dengan sistematis dan integratif agar data dapat diakses dan digunakan kembali oleh banyak orang.

Berbagai pangkalan data kehati tersebar di dalam jaringan:

- Global Biodiversity Information Facility (GBIF)
- Global database of biodiversity time series (BioTIME)

Era informasi memungkinkan (dan menuntut) kita memanajemen informasi dengan sistematis dan integratif agar data dapat diakses dan digunakan kembali oleh banyak orang.

Berbagai pangkalan data kehati tersebar di dalam jaringan:

- Global Biodiversity Information Facility (GBIF)
- Global database of biodiversity time series (BioTIME)
- An Anthropocene map of genetic diversity (iMapGenes)

Era informasi memungkinkan (dan menuntut) kita memanajemen informasi dengan sistematis dan integratif agar data dapat diakses dan digunakan kembali oleh banyak orang.

Berbagai pangkalan data kehati tersebar di dalam jaringan:

- Global Biodiversity Information Facility (GBIF)
- Global database of biodiversity time series (BioTIME)
- An Anthropocene map of genetic diversity (iMapGenes)

Yang lokal:

Era informasi memungkinkan (dan menuntut) kita memanajemen informasi dengan sistematis dan integratif agar data dapat diakses dan digunakan kembali oleh banyak orang.

Berbagai pangkalan data kehati tersebar di dalam jaringan:

- Global Biodiversity Information Facility (GBIF)
- Global database of biodiversity time series (BioTIME)
- An Anthropocene map of genetic diversity (iMapGenes)

Yang lokal:

Indonesian Biodiversity Information Facility

Era informasi memungkinkan (dan menuntut) kita memanajemen informasi dengan sistematis dan integratif agar data dapat diakses dan digunakan kembali oleh banyak orang.

Berbagai pangkalan data kehati tersebar di dalam jaringan:

- Global Biodiversity Information Facility (GBIF)
- Global database of biodiversity time series (BioTIME)
- An Anthropocene map of genetic diversity (iMapGenes)

Yang lokal:

- Indonesian Biodiversity Information Facility
- Biodiverskripsi

Era informasi memungkinkan (dan menuntut) kita memanajemen informasi dengan sistematis dan integratif agar data dapat diakses dan digunakan kembali oleh banyak orang.

Berbagai pangkalan data kehati tersebar di dalam jaringan:

- Global Biodiversity Information Facility (GBIF)
- Global database of biodiversity time series (BioTIME)
- An Anthropocene map of genetic diversity (iMapGenes)

Yang lokal:

- Indonesian Biodiversity Information Facility
- Biodiverskripsi
- Atlas Burung Indonesia

Data kehati memiliki berbagai macam atribut:

• ID unik

- ID unik
- nama spesies (binomial nomenclature, contoh: Oryza sativa, Gecko gecko, dll.)

- ID unik
- nama spesies (binomial nomenclature, contoh: Oryza sativa, Gecko gecko, dll.)
- lokasi perjumpaan (koordinat, nama daerah, dll.)

- ID unik
- nama spesies (binomial nomenclature, contoh: Oryza sativa, Gecko gecko, dll.)
- lokasi perjumpaan (koordinat, nama daerah, dll.)
- waktu perjumpaan (tanggal, jam, tahun, dll.)

- ID unik
- nama spesies (binomial nomenclature, contoh: Oryza sativa, Gecko gecko, dll.)
- lokasi perjumpaan (koordinat, nama daerah, dll.)
- waktu perjumpaan (tanggal, jam, tahun, dll.)
- kuantitas organisme (jumlah individu, biomassa, OTU, dll.)

- ID unik
- nama spesies (binomial nomenclature, contoh: Oryza sativa, Gecko gecko, dll.)
- lokasi perjumpaan (koordinat, nama daerah, dll.)
- waktu perjumpaan (tanggal, jam, tahun, dll.)
- kuantitas organisme (jumlah individu, biomassa, OTU, dll.)
- data abiotik pendukung (suhu, kondisi tanah, cahaya)

- ID unik
- nama spesies (binomial nomenclature, contoh: Oryza sativa, Gecko gecko, dll.)
- lokasi perjumpaan (koordinat, nama daerah, dll.)
- waktu perjumpaan (tanggal, jam, tahun, dll.)
- kuantitas organisme (jumlah individu, biomassa, OTU, dll.)
- data abiotik pendukung (suhu, kondisi tanah, cahaya)
- data organisme lain yang berkaitan (biomassa vegetasi, kelimpahan parasit, dll.)

Beberapa pangkalan menyediakan data yang langsung dapat diunduh dari dalam jaringan setelah pengguna melakukan *log in*.

Beberapa pangkalan menyediakan data yang langsung dapat diunduh dari dalam jaringan setelah pengguna melakukan *log in*.

GBIF memiliki API yang dapat digunakan via R.

Beberapa pangkalan menyediakan data yang langsung dapat diunduh dari dalam jaringan setelah pengguna melakukan *log in*.

GBIF memiliki API yang dapat digunakan via R.

```
library(rgbif)

## mencari data perjumpaan

occ_search(scientificName = "Bubalus", country = "ID", limit = 20)
buffaloID<-occ_search(scientificName = "Bubalus", country = "ID")
summary(buffaloID)
buffaloData<-buffaloID$data

head(buffaloData)</pre>
```

Menggunakan rgbif::occ_search() kita hanya akan mendapat maksimal 500 data perjumpaan.

Menggunakan rgbif::occ_search() kita hanya akan mendapat maksimal 500 data perjumpaan.

Seluruh data hanya dapat diperoleh langsung dari situs GBIF¹ atau rgbif::occ_download()².

Menggunakan rgbif::occ_search() kita hanya akan mendapat maksimal 500 data perjumpaan.

Seluruh data hanya dapat diperoleh langsung dari situs GBIF¹ atau rgbif::occ_download()².

Lebih banyak tentang menggunakan package rgbif dapat dilihat di sini.

Menggunakan rgbif::occ_search() kita hanya akan mendapat maksimal 500 data perjumpaan.

Seluruh data hanya dapat diperoleh langsung dari situs GBIF¹ atau rgbif::occ_download()².

Lebih banyak tentang menggunakan package rgbif dapat dilihat di sini.

- [1] Sudah harus mendaftar di gbif.org, menyediakan username dan password, lalu *log in* sebelum unduh.
- [2] Jika ingin menggunakan fungsi ini, kita harus lebih dulu mengatur Sys.setenv(GBIF_USER="username", GBIF_PWD="password", GBIF_EMAIL="e-mail") namun saat ini fungsi tersebut sedang bermasalah per 16/05/2019.

Tentang eksplorasi data

Apa itu eksplorasi data?

Eksplorasi data adalah siklus iteratif:

1. Membuat pertanyaan terkait data

Apa itu eksplorasi data?

Eksplorasi data adalah siklus iteratif:

- 1. Membuat pertanyaan terkait data
- 2. Menjawab pertanyaan dengan memvisualisasikan data

Apa itu eksplorasi data?

Eksplorasi data adalah siklus iteratif:

- 1. Membuat pertanyaan terkait data
- 2. Menjawab pertanyaan dengan memvisualisasikan data
- 3. Gunakan hasil eksplorasi untuk mempertajam pertanyaan/membuat pertanyaan baru

Beberapa pertanyaan untuk memulai

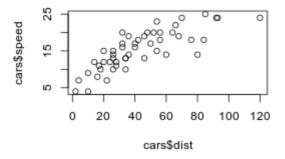
- 1. Variasi macam apa yang ada dalam variabel-variabel data saya?
 - Variasi adalah kecenderungan perubahan nilai dalam suatu variabel
- 1. Kovariasi macam apa yang ada di antara variabel-variabel dalam data saya?
 - Kovariasi adalah kecenderungan perubahan nilai dari dua atau lebih variabel

Tentang visualisasi data

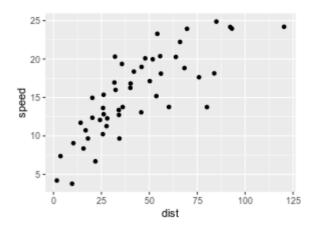
Ada banyak package di R untuk memvisualisasikan data sebagai tambahan dari bawaan package "menggambar" di R yaitu graphics, contoh: lattice, ggplot2, dll.

Berikut adalah perbandingan pembuatan plot menggunakan graphics dan ggplot2.

plot(cars\$dist, cars\$speed)



library(ggplot2)
ggplot(cars) +
 geom_jitter(aes(x=dist,y=speed)

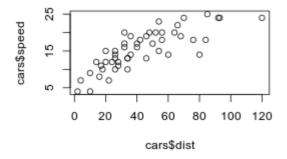


Tentang visualisasi data

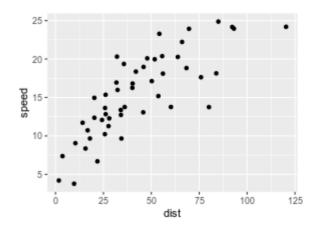
Ada banyak package di R untuk memvisualisasikan data sebagai tambahan dari bawaan package "menggambar" di R yaitu graphics, contoh: lattice, ggplot2, dll.

Berikut adalah perbandingan pembuatan plot menggunakan graphics dan ggplot2.

plot(cars\$dist, cars\$speed)



library(ggplot2)
ggplot(cars) +
 geom_jitter(aes(x=dist,y=speed)



Untuk materi kopdar ini, kita akan menggunakan ggplot2

Yang istimewa dari ggplot: grammar

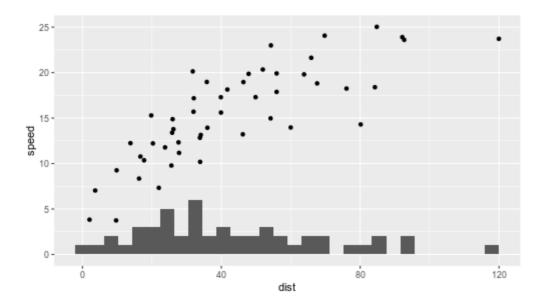
Sintaks atau struktur kode dalam ggplot2 sedemikian rupa sehingga sangat mudah untuk membuat grafik yang kompleks.

No.	Elemen	Fungsi	Keterangan
1.	Data		data mentah yang ingin kita visualisasikan
2.	Geometries	geom_	bentuk geometri untuk merepresentasikan data
3.	Aesthetics	aes()	keterangan tentang geometri atau objek statistik semisal gambar, ukuran, warna, dan posisi
4.	Scales	scale_	memetakan data ke dimensi-dimensi <i>aesthetics</i> , semisal kisaran data untuk memplot lebar elemen grafik atau faktor yang diberi warna

Yang istimewa dari ggplot: grammar

Mari kita simak contoh yang tadi, dengan tambahan grafik:

```
ggplot(cars) +
  geom_jitter(aes(x=dist,y=speed)) +
  geom_histogram(aes(x=dist))
```



Data yang akan kita gunakan

Dalam eksplorasi data kali ini, kita akan menggunakan data yang sudah saya siapkan:

1. Data kualitatif berupa data perjumpaan kelelawar Sulawesi dari GBIF.

```
lawar<-read.csv("input/bat.csv")</pre>
```

1. Data kuantitatif berupa jumlah dan kelimpahan kelelawar tropis dari BioTIME

```
mamtrop<-read.csv("input/biotime_rawdata.csv")
mamtrop_met<-read.csv("input/biotime_metadata.csv")</pre>
```

Mengapa kelelawar?

Kelelawar memiliki banyak manfaat dalam ekosistem:

Membantu penyerbukan beberapa tumbuhan komoditas

Kotorannya menjadi sumber nitrogen tumbuhan

Pemakan serangga dan menjadi pembasmi hama alami dalam industri perkebunan



Eksplorasi data perjumpaan GBIF

Berapa jumlah spesies per tahun?

Cek bentuk data

Langkah pertama dalam eksplorasi data adalah memahami struktur data: ada kolom apa saja? apa kelas datanya?

Hal ini dapat dilakukan dengan mudah melalui package dplyr.

```
library(dplyr)
glimpse(lawar)
```

```
## Observations: 2,677
## Variables: 106
                                     <int> 1. 2. 3. 4. 5. 6. 7. 8. 9. 10. ...
## $ X.1
                                     <int> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, ...
## $ X
                                     <fct> PhysicalObject, PhysicalObject,...
## $ type
## $ modified
                                     <fct> 2015-01-06, 2015-01-06, 2015-01...
## $ license
                                     <fct> CCBY, CCBY, CCBY, CCBY, CCBY, C...
## $ accessrights
                                     <fct> Western Australian Museum, West...
## $ bibliographiccitation
## $ references
                                     <fct> http://portal.vertnet.org/o/wam...
## $ institutionid
                                     <fct> , , , , , , , , , , , , , , ...
## $ collectionid
                                     <fct> , , , , , , , , , , , , , , , ...
## $ datasetid
                                     <fct> , , , , , , , , , , , , , , ...
## $ institutioncode
                                     <fct> WAM, WAM, WAM, WAM, WAM, WAM, 20/35
```

Berkutat dengan dplyr

Package dplyr adalah kelompok package tidyverse yang menggunakan operator pipa %>% untuk meneruskan fungsi.

Bandingkan kedua kode ini dan luarannya.

```
lawar %>%
  select(speciesname) %>%
  head()
```

```
## speciesname
## 1 Eonycteris spelaea
## 2 Rousettus celebensis
## 3 Cynopterus brachyotis
## 4 Cynopterus brachyotis
## 5 Cynopterus brachyotis
## 6 Rousettus amplexicaudatus
```

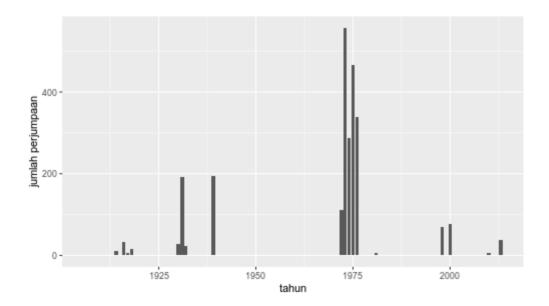
```
head(select(lawar, speciesname))
```

```
## speciesname
## 1 Eonycteris spelaea
## 2 Rousettus celebensis
## 3 Cynopterus brachyotis
## 4 Cynopterus brachyotis
## 5 Cynopterus brachyotis
## 6 Rousettus amplexicaudatus
```

Mari kita coba membuat plot untuk memvisualisasikan jumlah perjumpaan kelelawar berdasarkan tahun.

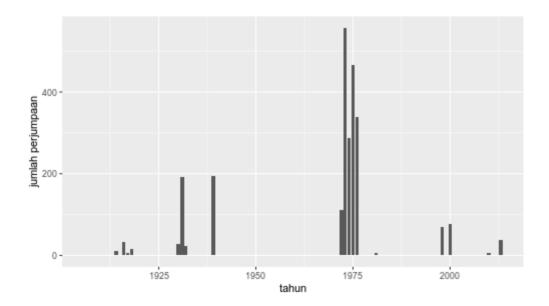
Mari kita coba membuat plot untuk memvisualisasikan jumlah perjumpaan kelelawar berdasarkan tahun.

```
library(ggplot2)
ggplot(lawar) +
  geom_bar(aes(x=year),na.rm = T) +
  labs(x="tahun",y="jumlah perjumpaan")
```



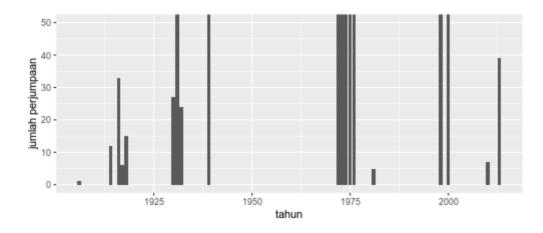
Mari kita coba membuat plot untuk memvisualisasikan jumlah perjumpaan kelelawar berdasarkan tahun.

```
library(ggplot2)
ggplot(lawar) +
  geom_bar(aes(x=year),na.rm = T) +
  labs(x="tahun",y="jumlah perjumpaan")
```



Kita bisa melihat apakah ada data di area tersebut dengan mendefinisikan sumbu y dari 0 hingga 20.

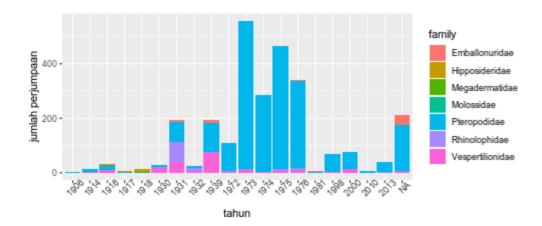
```
ggplot(data=lawar) +
  geom_bar(aes(x=year), na.rm = T)+
  coord_cartesian(ylim=c(0,50)) + #<< kode untuk mengatur sumbu y
  labs(x="tahun",y="jumlah perjumpaan")</pre>
```



Apa observasi penting dari data ini?

Tampak bahwa data perjumpaan memang bias pada tahun 1970an. Spesimen tidak merata ada di setiap tahun.

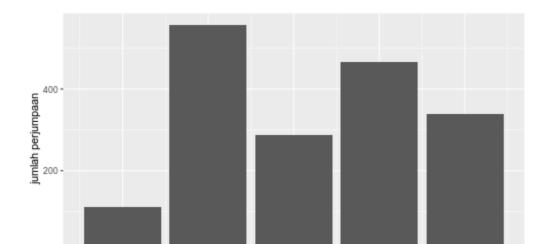
Tahun bisa diubah menjadi faktor yang bersifat kategori alih-alih angka kuantitatif.



Penampilan data tahun yang demikian akan menimbulkan persepsi distribusi kekayaan spesies yang berubah seiring waktu padahal ada bias pencuplikan.

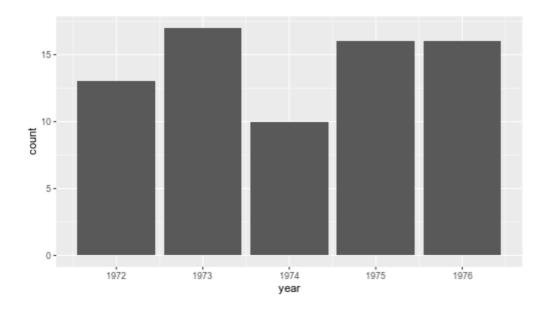
Kita ambil saja interval tahun yang kontinu, yakni dari tahun 1972 sampai dengan 1976.

```
lawar %>% filter(1972<=year & year <=1976) %>%
  ggplot() +
  geom_bar(aes(x=year), na.rm=T) +
  labs(x="tahun",y="jumlah perjumpaan")
```



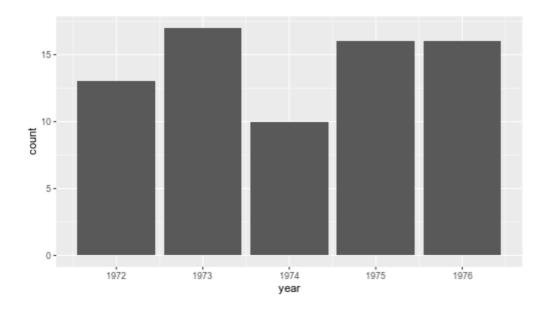
Lalu kita bisa menampilkan jumlah spesies per tahun

```
lawar %>% filter(1972<=year & year <=1976) %>%
  group_by(year) %>%
  count(speciesname) %>%
  ggplot() +
  geom_bar(aes(x=year), na.rm=T)
```



Lalu kita bisa menampilkan jumlah spesies per tahun

```
lawar %>% filter(1972<=year & year <=1976) %>%
  group_by(year) %>%
  count(speciesname) %>%
  ggplot() +
  geom_bar(aes(x=year), na.rm=T)
```



Eksplorasi data kelimpahan dari BioTIME

Bagaimana tren kelimpahan spesies di ekosistem tropis?

Cek data apakah sudah terbaca dengan benar

Cek data apakah sudah terbaca dengan benar

Cek tipe variabel yang ada dalam data

Cek data apakah sudah terbaca dengan benar

Cek tipe variabel yang ada dalam data

Visualisasikan data yang ingin kita eksplor

Mari kita lihat ada variabel apa saja

Apa saja fungsi yang dapat kita gunakan?

Mari kita lihat ada variabel apa saja

Apa saja fungsi yang dapat kita gunakan?

```
glimpse(mamtrop)
## Observations: 3,142
## Variables: 10
## $ STUDY ID
               ## $ ABUNDANCE
               <dbl> 1, 1, 1, 4, 9, 7, 2, 3, 2, 4, 3, 2, 2, 4, 4, 1, 3,...
               <dbl> 55, 62, 62, 250, 538, 426, 126, 187, 128, 217, 196...
## $ BIOMASS
## $ YEAR
               <int> 2006, 2007, 2007, 2008, 2008, 2008, 2010, 2011, 20...
## $ LATITUDE
               <dbl> -28.5853, -28.5853, -28.5853, -28.5853, -28.5853, ...
## $ LONGITUDE
               <dbl> -48.9731, -48.9731, -48.9731, -48.9731, -48.9731, ...
               ## $ PLOT
               ## $ DEPTH
## $ SAMPLE_DESC
              <fct> 2006_1, 2007_1, 2007_1, 2008_1, 2008_1, 2008_1, 20...
## $ GENUS_SPECIES <fct> Artibeus fimbriatus, Artibeus fimbriatus, Artibeus...
```

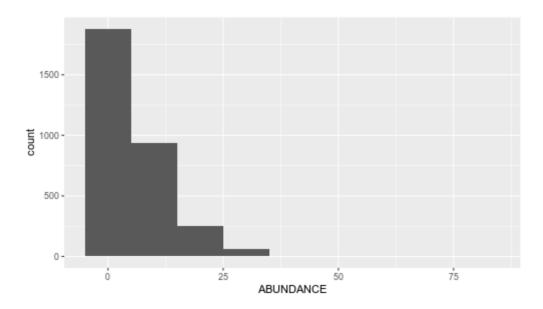
Mari kita lihat ada variabel apa saja

glimpse(mamtrop_met)

```
## Observations: 10
## Variables: 49
## $ STUDY_ID
                   ## $ REALM
                   <fct> Terrestrial, Terrestrial, Terrest...
## $ CLIMATE
                   <fct> Temperate/Tropical, Tropical, Tropical, Tropic...
## $ BIOME_MAP
                   <fct> Tropical and subtropical moist broadleaf fores...
## $ ID_DATASETS
                   ## $ TAXA
                   <fct> Mammals, Mammals, Mammals, Mammals, M...
## $ ORGANISMS
                   <fct> Bat, bats, bats, bats, bats, bats, bats, bats, ...
## $ TITLE
                   <fct> Bats (Mammalia Chiroptera) in restinga in the ...
                   <fct> AB, A, A, A, A, A, A, A, A
## $ AB_BIO
                   <fct> Y, Y, Y, Y, Y, Y, Y, Y, Y, Y
## $ HAS_PLOT
                   <int> 10, 5, 5, 5, 5, 5, 3, 3, 3
## $ DATA_POINTS
## $ START_YEAR
                   <int> 2006, 1997, 1997, 1997, 1997, 1997, 2003, 2003...
## $ END_YEAR
                   <int> 2016, 2013, 2013, 2013, 2013, 2013, 2005, 2005...
## $ CENT_LAT
                   <dbl> -28.608900, -2.386381, -2.386381, -2.386381, -...
## $ CENT_LONG
                   <dbl> -48.98125, -59.91877, -59.91877, -59.91877, -5...
## $ NUMBER_OF_SPECIES <int> 13, 45, 45, 45, 45, 45, 43, 43, 43
## $ NUMBER_LAT_LONG
                   <int> 2, 12, 12, 12, 12, 12, 17, 17, 17
```

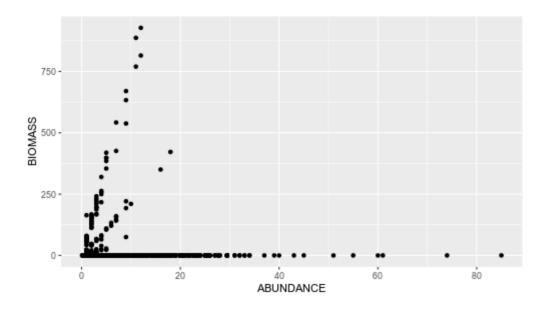
Melihat variasi data

```
ggplot(mamtrop) +
  geom_histogram(aes(ABUNDANCE), binwidth = 10)
```



Melihat kovariasi data

```
ggplot(mamtrop) +
  geom_jitter(aes(x=ABUNDANCE,y=BIOMASS))
```



sumbu x adalah waktu

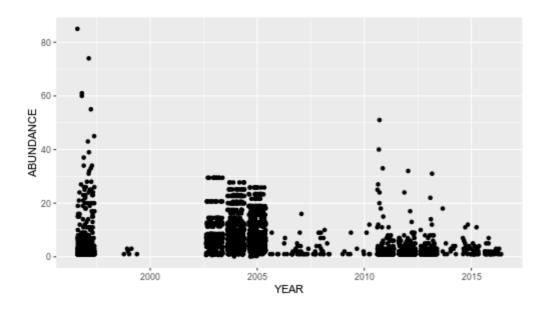
sumbu x adalah waktu

sumbu y adalah kelimpahan

sumbu x adalah waktu

sumbu y adalah kelimpahan

```
ggplot(mamtrop) +
  geom_jitter(aes(x=YEAR,y=ABUNDANCE))
```



Apalagi yang dapat dieksplor?

Salurkan kode Anda dalam kopdar!

Terima kasih!

Slides created via the R package **xaringan**.

The chakra comes from remark.js, **knitr**, and R Markdown.